

Генеративные адверсальные атаки на последовательные данные

Задача

$$\mathcal{L}_{\text{cls}}(\mathbf{x} + \delta, y) \rightarrow \max, \|\delta\| < \epsilon$$

GENADA

В работе предлагается обучать отдельную модель генератор создавать шаги в пространстве входов, приводящие к ошибкам классификатора

$$\delta = (\tanh \circ G)^{(k)}(x)$$

The solution

- 1) Предобучить генератор повторять сильную white-box атаку, например iFGSM,
- 2) Обучить генератор максимизировать $\mathcal{L}_{\text{cls}}(\mathbf{x} + \delta, y)$, либо минимизировать $\mathcal{L}(\mathbf{x} + \delta, \neg y)$.
- 3) Получаем сильную, быструю, одношаговую black-box атаку.

